

TEMA 1

Sistemas de ecuaciones lineales

• REGLA DE CRAMER

$$A = (a_{ij})_{n \times n}, x = (x_i), b = (b_i)$$

$$Ax = b \Leftrightarrow x_i = \frac{\det(B_j)}{\det(A)} \text{ con } B_j = \begin{pmatrix} 1 & \dots & 1 & b & 1 & \dots & 1 \end{pmatrix}$$

• Como el costo de calcular un determinante de una matriz de tamaño $n \times n$ es una $\mathcal{O}(n!)$ ("o grande de $n!$ ") es poco eficiente.

• MÉTODO DE GAUSS

$$A = (a_{ij})_{n \times n}, x = (x_i)_{n \times 1}, b = (b_i)_{n \times 1}$$

$$1) a_{i,i} \cdot \frac{-a_{ii}}{a_{ii}} + a_{i,i} \quad \forall i=2, \dots, n \rightarrow \text{anulamos } x_i \text{ en la ec. } i\text{-ésima con } i=2, \dots, n.$$

$$2) \text{ Repetimos } \forall j \quad a_{j,j} \cdot \frac{-a_{jj}}{a_{jj}} + a_{j,i} \text{ con } i=j+1, \dots, n.$$

El costo de aplicar el método de Gaus es una $\mathcal{O}(n^3)$.

• MATRIZ ELEMENTAL

$L_i = \begin{bmatrix} 1 & & & & \\ 0 & \ddots & & & \\ & & 1 & & \\ & & & \ddots & \\ & & & & 1 \end{bmatrix}$ Una matriz elemental es cualquier matriz obtenida al aplicarle a la matriz identidad una operación elemental.

factorización LU Dada $A \in \mathcal{M}_{n \times n}(\mathbb{K})$ con $\mathbb{K} = \mathbb{R} \circ \mathbb{C}$, esta posee una factorización LU si $\exists L$ triangular inferior, U triangular superior.

$$Ax = b \Leftrightarrow L U x = b \Leftrightarrow U x = y \wedge Ly = b$$

Costo de hacer $L U \rightarrow \mathcal{O}(n^3)$

Costo resolución $\rightarrow \mathcal{O}(n^2)$

→ OBTENCIÓN DE FACTORIZACIÓN LU

Se hace de forma inductiva o constructiva.

$$A = L \cdot U \Leftrightarrow \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \dots & \dots & \dots \\ a_{nn} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & & & \\ \dots & \dots & \dots & \\ l_{nn} & \dots & l_{nn} \end{bmatrix} \cdot \begin{bmatrix} u_{11} & \dots & u_{1n} \\ \dots & \dots & \dots \\ 0 & \dots & u_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} \cdot u_{11} & \dots & l_{11} \cdot u_{1n} \\ \dots & \dots & \dots \\ l_{nn} \cdot u_{11} & \dots & l_{nn} \cdot u_{1n} + \dots + l_{nn} \cdot u_{nn} \end{bmatrix}$$

$$\Rightarrow l_{11} \cdot u_{1j} = a_{1j}$$

Elección de doofittle $\rightarrow l_{ii} = 1 \quad \forall i$ Elección de CROUT $\rightarrow u_{ii} = 1 \quad \forall i$

$$\Rightarrow l_{11} \cdot u_{11} = \frac{\det(A_{11})}{\det(A_{n-1})}$$

$$\text{Fijando } l_{ii} = 1 \quad \forall i=1, \dots, n \Rightarrow \begin{cases} u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} & j=i, i+1, \dots, n \\ l_{ji} = \frac{1}{u_{ii}} \left(a_{ji} - \sum_{k=1}^{i-1} l_{jk} u_{ki} \right) & j=i+1, \dots, n \end{cases}$$

→ EXISTENCIA

Sea $A \in \mathcal{M}_{n \times n}(\mathbb{K})$ con $\det(A) \neq 0$. Entonces, $\exists L, U : A = LU \Leftrightarrow \forall k=1, \dots, n \det(A_{kk}) \neq 0$.

• A SIMÉTRICA

$$\Leftrightarrow A = A^t := A'$$

$$\begin{cases} A = L \cdot U \\ A^t = (L \cdot U)^t = U^t \cdot L^t \end{cases}$$

$$\text{Si } \det(A) \neq 0 \Rightarrow \det(U) = \prod_{i=1}^n u_{ii} \neq 0 \Rightarrow \forall i=1, \dots, n \quad u_{ii} \neq 0 \Rightarrow$$

$$\Rightarrow U = \begin{pmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ 0 & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & u_{nn} \end{pmatrix} = \underbrace{\begin{pmatrix} u_{11} & 0 & \dots & 0 \\ 0 & u_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & u_{nn} \end{pmatrix}}_D \cdot \underbrace{\begin{pmatrix} 1 & \tilde{u}_{12} & \dots & \tilde{u}_{1n} \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix}}_{M^t}$$

$$\tilde{u}_{ij} = u_{ij}/u_{ii}$$

Entonces, si A es simétrica ($A = A^t$) y $\det(A) \neq 0$, $A = L D L^t$ (porque $L = M$)

Prop: Dada $L = \begin{pmatrix} 1 & \dots & 0 \\ \tilde{e}_{12} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$ ($\Rightarrow \det(L) = 1 \neq 0$) $\Rightarrow \exists L^{-1}$ con $L^{-1} = \begin{pmatrix} 1 & \dots & 0 \\ \tilde{e}_{12} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}$

Esta descomposición es similar a los autovalores de la matriz A ya que $(\lambda \in \sigma(A) \Leftrightarrow A \cdot x = \lambda x ; \sigma(A) = \{\text{raíces de } \det(A - \lambda I)\})$:

$$A \cdot x = L D L^t \cdot x = \lambda x \Leftrightarrow D L^t \cdot x = \lambda L^t x$$

• A SIMÉTRICA DEFINIDA POSITIVA (S.P.D.)

$$\Leftrightarrow A = A^t \text{ y } \forall x \in \mathbb{K}^n \quad x^t A x > 0 \text{ y } x^t A x = 0 \Leftrightarrow x = 0$$

$$\lambda \in \sigma(A) \Leftrightarrow \exists v \in \mathbb{K}^n \setminus \{0\} : A v = \lambda v \Rightarrow \underbrace{v^t A v}_0 = \lambda \underbrace{v^t v}_{\sum_{i=1}^n v_i^2 > 0} \Rightarrow \lambda > 0$$

Así que $A = L D L^t$ con $D = \text{diag}(d_1, \dots, d_n)$ donde $d_i > 0 \quad \forall i \in \{1, \dots, n\}$.

Por lo que podemos considerar $d_i^{1/2} \quad \forall i \in \{1, \dots, n\} \Rightarrow$

$$\Rightarrow \mathcal{D}^{1/2} = \begin{pmatrix} d_1^{1/2} & 0 \\ 0 & d_n^{1/2} \end{pmatrix} \text{ con } D = \mathcal{D}^{1/2} \cdot \mathcal{D}^{1/2} \Rightarrow A = L \mathcal{D}^{1/2} L^t = \underbrace{L \mathcal{D}^{1/2}}_{G^t} \cdot \underbrace{\mathcal{D}^{1/2} L^t}_{G^t} = G \cdot G^t$$

$$G^t = (\mathcal{D}^{1/2})^t L^t = \mathcal{D}^{1/2} L^t$$

Si $\exists G = \begin{pmatrix} g_{11} & 0 \\ g_{12} & g_{22} \\ \vdots & \vdots \\ 0 & g_{nn} \end{pmatrix} : A = G \cdot G^t \Rightarrow A \text{ es SVD.}$
con $g_{kk} > 0$

→ ALGORITMO DE OBTENCIÓN DE CHOLESKY

$$g_{11} = \sqrt{a_{11}}$$

$$g_{21} = \frac{a_{21}}{g_{11}}$$

...

$$g_{k1} = \frac{a_{k1}}{g_{11}}$$

$$g_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} g_{ik}^2}$$

$$g_{ji} = \frac{1}{g_{ii}} \left[a_{ij} - \sum_{k=1}^{i-1} g_{ik} g_{jk} \right]$$

j = i+1, ..., n

$$9 + 25 + x^2 = 35$$

$$x^2 = 1 \Rightarrow x = 1$$

$$6 + 1 \cdot x = 1 \Rightarrow x = -5$$

$$12 - 10 + 1 \cdot x = 5 \Rightarrow x = 3$$

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 2 & 5 & 1 & 10 \\ 3 & 1 & 35 & 5 \\ 4 & 10 & 5 & 45 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{2} & 1 & 0 & 0 \\ \frac{3}{4} & -5 & 1 & 0 \\ \frac{1}{4} & 2 & 3 & 4 \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 & 4 \\ 0 & 1 & -5 & 2 \\ 0 & 0 & 1 & 3 \\ 0 & 0 & 0 & 4 \end{pmatrix}$$

factorización LU con permutaciones

Matrices de permutación.

$$P_{ij} = \begin{pmatrix} 1 & & & & 0 \\ & \ddots & & & \\ & & 1 & & \\ & & & \ddots & \\ 0 & & & & 1 \end{pmatrix} \quad \rightarrow P_{ij} \cdot A \text{ intercambiamos las columnas } i \text{ y } j.$$

$$P_{ij}^t = P_{ij}^{-1} = P_{ji}$$

→ PERMUTACIÓN PARCIAL

$$PA = LU \text{ donde } P \text{ matriz de permutaciones}$$

* PASOS a seguir (iteración k -ésima)

I) Elegimos el pivote como el mayor elemento de la columna k -ésima (sup. filap).

II) Se permutan la fila k y P de $A^{(k)}$ y $b^{(k)}$ ($\cdot P_{kp}$)

III) Eliminamos los elementos de la columna k bajo la diagonal.

→ PERMUTACIÓN TOTAL

Se optimiza el algoritmo anterior buscando el mayor elemento entre las filas y columnas $i, j \geq k$ (iteración k -ésima) \Rightarrow se multiplica a izquierda y derecha por las matrices P para permutar filas y columnas.

factorización QR

Cuando la matriz es cuadrada, se dice que es una matriz ortogonal

y sus columnas y filas son ortonormales.

$$x \in \mathbb{K}^n \Rightarrow x = \langle x, q_1 \rangle q_1 + \dots + \langle x, q_n \rangle q_n$$

T^a de Gram-Schmidt $\{x_1, \dots, x_n\}$ LI en $\mathbb{K}^d \Rightarrow \exists \{y_1, \dots, y_n\} \subset \mathbb{K}^d : \langle x_1, \dots, x_p \rangle = \langle y_1, \dots, y_p \rangle$

$$y_1 = \frac{x_1}{\|x_1\|}, \quad \forall j > 1 \quad \tilde{y}_j = x_j - \sum_{s=1}^{j-1} \langle x_j, y_s \rangle y_s \quad \rightarrow \quad y_j = \frac{\tilde{y}_j}{\|\tilde{y}_j\|}$$

Reescrito:

$$\begin{cases} x_1 = \gamma_{11} y_1 \\ x_2 = \gamma_{12} y_1 + \gamma_{22} y_2 \\ \dots \\ x_n = \gamma_{1n} y_1 + \gamma_{2n} y_2 + \dots + \gamma_{nn} y_n \end{cases} \quad \Rightarrow A = \begin{bmatrix} x_1 & | & x_2 & | & \dots & | & x_n \end{bmatrix} = \begin{bmatrix} y_1 & | & y_2 & | & \dots & | & y_n \end{bmatrix} \cdot \begin{bmatrix} \gamma_{11} & \gamma_{12} & \dots & \gamma_{1n} \\ 0 & \gamma_{22} & \dots & \gamma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \gamma_{nn} \end{bmatrix} = QR$$

Donde Q es ortogonal y R triangular superior.

→ MATRIZ DE HOUSEHOLDER

Dado $u \in \mathbb{R}^n$, la matriz de Householder asociada a u es $H_u = I - 2 \frac{u u^t}{u^t u}$.

Prop.: 1. $H_u^t = H_u$ 2. $H_u \cdot H_u = I$ 3. Las matrices de Householder son ortogonales, simétricas y unitarias \Rightarrow preservan longitudes. $\rightarrow H_u$ simétrica, $H_u^t = I$ y $\|H_u\|_2 = 1$

Teo.: Dado $a \in \mathbb{R}^n$, buscamos $u \in \mathbb{R}^n : H_u a = \begin{pmatrix} \|a\|_2 \\ 0 \end{pmatrix}$ con $\|H_u a\| = \|a\| = \|a\|_2$

$$u = -\|a\|_2 e_1 + a \Rightarrow H_u(a) = (\|a\|_2, 0, \dots, 0)^t$$

$$\bar{u} = \|a\|_2 e_1 + a \Rightarrow H_{\bar{u}}(a) = (-\|a\|_2, 0, \dots, 0)^t$$

Obs.: 1. $u = (-\|a\|, 0, \dots, 0)^t + (a_1, \dots, a_n)^t = (-\|a\| + a_1, a_2, \dots, a_n)^t$

$a \perp e_1 \Rightarrow$ todo OK.

• $a \parallel e_1$ (caso II) $\Rightarrow a_1 \approx 1, a_2 \approx 0, \dots, a_n \approx 0 \Rightarrow \|a\| \approx |a_1|$

$$a_1 > 0 \Rightarrow -\|a\| + a_1 \approx 0 \Rightarrow \text{ponemos } -\|a\| + a_1 = \frac{(-\|a\| + a_1)(-\|a\| - a_1)}{-\|a\| - a_1} = \frac{-a_1^2 + \|a\|^2}{-\|a\| + a_1} = -\frac{a_1^2 + \dots + a_n^2}{a_1 + \|a\|}$$

que es ↑ estable

2. $a \in \mathbb{R}^n, u = -\|a\|e_1 + a \Rightarrow H_u = I - 2 \frac{uu^t}{u^tu}, H_u(a) = \begin{pmatrix} \|a\| \\ 0 \\ \vdots \\ 0 \end{pmatrix}$

$$H_u(b) = b - 2 \frac{uu^t}{u^tu} b = b - 2 \frac{u^t b}{u^tu} u$$

★ Factorización QR usando las transformaciones de Householder

Dada $A \in \mathbb{K}^{m \times n}$ una factorización QR de A es una de la forma $A = QR$ donde $Q \in \mathbb{K}^{m \times m}$ ortogonal y $R \in \mathbb{K}^{m \times n}$ triangular superior.

Si $p \in \min\{m, n\}$, el método de Householder para obtener la factorización consiste en encontrar p matrices Householder H_1, \dots, H_p tq $R = H_p \cdots H_2 H_1 A$ sea una matriz triangular sup. $\Rightarrow Q = H_1^t \cdots H_p^t : A = QR$

• $R_0 = A$ y $Q_0 = H_0 = \text{Id}$

• $Q_K = H_K Q_{K-1} R_K = H_K R_{K-1} \rightarrow$

$$R_K = \begin{pmatrix} \text{celdas} \\ \vdots \\ \text{celdas} \\ \vdots \\ \text{celdas} \\ 0 & \text{celdas} \\ \vdots & \text{celdas} \\ 0 & \text{celdas} \end{pmatrix} \leftarrow \text{fila } K$$

columna K → R_K

Con $\tilde{r}_K = (r_{KK}, \dots, r_{mK})^t \in \mathbb{K}^{m-K+1}$, consideremos $\tilde{H}_{K+1} = H(\tilde{v}_K)$ la matriz de Householder tq $\tilde{H}_{K+1} \cdot \tilde{r}_K = (1, 0, \dots, 0)$.

Sea $\tilde{H}_{K+1} = \begin{pmatrix} \text{Id}_{K-1} & 0 \\ 0 & \tilde{H}_{K+1} \end{pmatrix}$ donde $\tilde{H}_{K+1} = H(v_{K+1}) \in (0, \dots, 0, \tilde{v}_K)^t = v_K$

Entonces, construyendo $Q_{K+1} = H_{K+1} \cdot Q_K$ y $R_{K+1} = H_{K+1} \cdot R_K = Q_{K+1} \cdot A$

Retramos el proceso hasta obtener la matriz triangular $R = R_p = Q_p A$ y poniendo $Q = Q_p^t \Rightarrow A = QR$ que SIEMPRE EXISTE.

→ MATRIZ DE GIVENS

La matriz de transformación de Givens es de la forma

Mediante transformaciones de Givens se puede reducir la matriz de un problema de mínimos cuadrados, en n etapas,

a una triangular superior R. En cada una de estas etapas j, se harán cero, uno a uno, los coeficientes $j+1$ a m.

72

$$\begin{bmatrix} 1 & \dots & 0 & 0 \\ \dots & \cos \theta & -\sin \theta & 0 \\ \dots & \sin \theta & \cos \theta & 0 \\ 0 & \dots & 1 & \dots \end{bmatrix}$$

T^a de Schur $A \in M_n(\mathbb{C}) \Rightarrow \exists U \in M_n(\mathbb{C})$ unitaria ($U^* = U^{-1}$) : $U^{-1}AU = \begin{pmatrix} \lambda_1 & * \\ 0 & \lambda_n \end{pmatrix} = T$
 factorización de Schur $\Rightarrow A = UTU^*$ con $T = \begin{pmatrix} \lambda_1 & * & * \\ * & \ddots & * \\ 0 & * & \lambda_n \end{pmatrix}$ donde $\lambda_i \in \sigma(A)$ $i=1,\dots,n$

Dada $A \in M_n(\mathbb{C})$, tomamos $\lambda_1 \in \sigma(A)$ y sea v_1 el correspondiente autovector $v_1 : \|v_1\|=1$. Elegimos $n-1$ vectores w_2, \dots, w_n tq $\{v_1, w_2, \dots, w_n\}$ una base ortogonal de $\mathbb{C}^n \Rightarrow V_1 = (v_1 \ w_2 \ \dots \ w_n)$ que cumple $V_1^{-1} \cdot A \cdot V_1 = \begin{pmatrix} \lambda_1 & * \\ 0 & A_1 \end{pmatrix}$, donde $A_1 \in M_{n-1}(\mathbb{C})$. Repitiendo el proceso con $A_1 \rightarrow V_2^{-1} \cdot A_1 \cdot V_2 = \begin{pmatrix} \lambda_2 & * \\ 0 & A_2 \end{pmatrix}$ donde V_2 es unitaria.

Así que,

$$Q_2 = V_1 \hat{V}_2 = V_1 \begin{pmatrix} 1 & 0 \\ 0 & V_2 \end{pmatrix} \Rightarrow Q_2^* A Q_2 = \begin{pmatrix} \lambda_1 & * & * \\ 0 & \lambda_2 & * \\ 0 & 0 & A_2 \end{pmatrix}^*$$

Continuando el proceso, $\exists V_3, \dots, V_n : Q := V_1 \hat{V}_2 \hat{V}_3 \dots \hat{V}_n \rightarrow T = Q^* A Q \Rightarrow A = Q T Q^*$
 triángular superior

Prop.: $Q^* \cdot Q = \text{Id}$ con Q unitaria, ortogonal y $\lambda \in \sigma(Q) \Rightarrow |\lambda| = 1$

A es normal si $A^* A = I_n = AA^*$. Si $A^* A = I_n$ se dice que A es unitaria.

Teo: A es normal $\Leftrightarrow A = U \cdot \text{diag}(\lambda_1, \dots, \lambda_n) \cdot U^*$ con U unitaria.

Teo: $A = A^*$ \Leftrightarrow A diagonalizable con una base ortogonal y con autovalores reales.

Teo: $A \in M_n(\mathbb{R})$ y $A = A^t \Leftrightarrow A = P \cdot \text{diag}(d_1, \dots, d_n) \cdot P^t$ con $d_i \in \mathbb{R}$ $i=1, \dots, n \Rightarrow P := Q$ y $P^t = Q^t$

Una matriz A es simétrica definida positiva (S.P.D.) si $A = A^t$ y es PD, es decir, si $\forall x \in \mathbb{R}^n \setminus \{0\} \quad x^t A x = \sum_{i,j=1}^n a_{ij} x_i x_j > 0$

Prop.: Dada $A \in M_{m \times n}(\mathbb{K}) \Rightarrow A^t A \in M_m(\mathbb{K})$ es hermética y $\forall \lambda \in \sigma(A^t A) \quad \lambda > 0$.

Los autovalores de $A^t A$ reciben el nombre de valores singulares de $A \in M_{m \times n}$.

Prop: Si A tiene rango máximo, entonces $\sigma_j \in \sigma(A^t A) \Rightarrow \sigma_j > 0$

Dada $A \in M_{m \times n}(\mathbb{K})$ tal que $A^t A$ es simétrica con $\sigma(A^t A) > 0$, tomamos $\sigma_1, \dots, \sigma_n \in \sigma(A^t A) : \sigma_1 \geq \dots \geq \sigma_n \geq 0$

con $\sigma_{n+m-i} = 0$ ($i=r+1, \dots, n$) si $\text{rang}(A^t A) = r$.

Si $\forall i=1, \dots, n$ tomamos $e_i : A^t A e_i = \sigma_i e_i$ ($\{e_1, \dots, e_n\}$ base ortogonal) y $u_i = \frac{1}{\sigma_i} A e_i$ ($\Rightarrow \{u_1, \dots, u_n\}$ cumple que $u_i^t u_i = \frac{1}{\sigma_i^2}$ y $(\neq j) \quad u_i^t u_j = 0$ pues $e_i^t e_j = 0$).

Vamos a llegar a $A = U \Sigma V^t$ con $A \in M_{m \times n}(\mathbb{K})$, $U \in M_m(\mathbb{K})$ unitaria y $V \in M_n(\mathbb{K})$ unitaria.

$$A = (a_1 \dots a_n) = (u_1 | \dots | u_n) \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & 0 \end{pmatrix} (v_1 | \dots | v_n)^t = U \Sigma V^t \Rightarrow AV = U\Sigma \Rightarrow$$

$$\Rightarrow A(v_1 | \dots | v_n) = (u_1 \sigma_1 | \dots | u_n \sigma_n)$$

Tomamos v_1, \dots, v_n tq $(A^t A) v_i = \sigma_i v_i \Rightarrow \{Av_1, \dots, Av_n\} \quad (Av_i)^t (Av_j) = \sigma_j v_i^t v_j = \begin{cases} \sigma_i^2 & \text{si } i=j \\ 0 & \text{si } i \neq j \end{cases}$

T^a de Existencia de SVD Sea $A \in M_{m \times n}(\mathbb{K})$ ($m \geq n$) $\Rightarrow \exists U \in M_m(\mathbb{K})$, $V \in M_n(\mathbb{K})$ unitarias y $\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & 0 \end{pmatrix} \in M_{m \times n}(\mathbb{K}) : A = U \Sigma V^t$.

CONSTRUCCIÓN

$A \cdot A^H \in M_m(\mathbb{K})$ hermética \Rightarrow el espectro es real y positivo.

$\sigma(A \cdot A^H) = \{\lambda_1, \dots, \lambda_m\}$ ($\lambda_1 \geq \dots \geq \lambda_m \geq 0$) \Rightarrow consideremos $\{u_1, \dots, u_m\}$ base ortonormal de autovectores de $AA^H \rightarrow j=1, \dots, m \quad AA^H u_j = \lambda_j u_j$.

$U = (u_1 | \dots | u_m) \in M_m(\mathbb{K})$ ortogonal.

↓

$$(AA^H)U = U \cdot \text{diag}(\lambda_1, \dots, \lambda_m) \Leftrightarrow U \cdot D \Rightarrow AA^H = UDU^H$$

$$AA^H u_j = \begin{cases} \lambda_j u_j & j=1, \dots, r \\ 0 & j=r+1, \dots, m \end{cases} \quad \begin{matrix} \lambda_j u_j = \sigma_j^2 u_j \\ \sqrt{\lambda_j} = \sigma_j \end{matrix} \quad \begin{matrix} \{v_1, \dots, v_r\} \text{ familia} \\ \text{ortonormal de } \mathbb{K}^n \end{matrix}$$

$$\text{rang}(AA^H) = r < m$$

$$v_j = \frac{1}{\sigma_j} A^H u_j$$

$$\Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 & \dots & 0 \end{pmatrix} \quad \Rightarrow U^H A = \Sigma V^H \Rightarrow A = U \Sigma V^H$$

FORMA REDUCIDA DE SVD

$A^H A \in M_n(\mathbb{K})$ simétrica $\Rightarrow (A^H A) V = V \cdot \text{diag}(\lambda_1, \dots, \lambda_n) \Rightarrow AV = \hat{U} \hat{\Sigma}$

$$\sigma_i = \sqrt{\lambda_i} \quad y \quad u_i = \frac{1}{\sigma_i} A v_i \quad i=1, \dots, n$$

$$V = (v_1 | \dots | v_n), \quad \hat{U} = (u_1, \dots, u_n), \quad \hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_n)$$

Lema: Los autovalores no nulos de AB coinciden con los de BA .

Dem: A normal ($A^H A = AA^H$) $\Rightarrow \forall \lambda_i \in \sigma(A) \quad \sigma_i = |\lambda_i|$

mínimos cuadrados \Rightarrow dada la familia de puntos $\{(x_i, y_i)\}_{i=0}^m$ con abscisas distintas 2 a 2.

Sabemos que $\exists q$ polinomio interpolador de grado n sumo m tq $\forall i \quad q(x_i) = y_i$ \Rightarrow en general, si $n < m \quad \nexists q$ polinomio interpolador de grado $\leq n \Rightarrow$ buscamos un polinomio $p(x)$ tq minimice $\|(y_0 - p(x_0)), \dots, y_m - p(x_m)\|$, para ello introducimos los sistemas sobredeterminados.

sean $n < m$, $A \in M_{m \times n}(\mathbb{R})$ y $b \in \mathbb{R}^m$: $Ax = b$ para $x \in \mathbb{R}^n$.

Buscamos minimizar $\|Ax - b\|_2$ con $\text{rang}(A) = n < m$

Teo: $x \in \mathbb{K}^m$ minimiza $\|Ax - b\|_2$ con $A \in M_{m \times n}(\mathbb{K})$ y $b \in \mathbb{K}^m \Leftrightarrow r = Ax - b$ es ortogonal a $\text{Img}(A)$.

Teo: $x \in \mathbb{K}^n = \min \{ \|Ay - b\|_2 : y \in \mathbb{K}^m \} \Leftrightarrow A^H A x = Ab$.

Formas de resolver $\min \{ \|Ax - b\|_2 : x \in \mathbb{K}^n \}$.

I. $A^H A x = A^H b \sim$ podemos usar Choleski en $A^H A$ ya que es def. positiva y hermética $\Rightarrow A^H \cdot A = G^H \cdot G$ con $G = \begin{pmatrix} g_{11} & & 0 \\ g_{21} & \ddots & \\ \vdots & & g_{nn} \end{pmatrix}$ con $g_{ii} > 0$.

II. Usando QR: $A = (q_1 | \dots | q_n) \begin{pmatrix} r_{11} & & \\ & \ddots & \\ 0 & & r_{nn} \end{pmatrix} = \hat{Q} \cdot \hat{R}$ $\begin{matrix} \text{columnas} \\ \text{ortonormales} \end{matrix} \quad \begin{matrix} \hat{r}_{11} & \ddots & \hat{r}_{nn} \\ M_{m \times n} & M_{n \times n}(\mathbb{K}) \end{matrix} \quad \begin{matrix} \hat{Q} \sim Q \text{ completando base} \\ \text{ortonormal de } \mathbb{K}^m \end{matrix}$

$$\|Ax - b\|_2 = \|QRx - b\|_2 = \|Q\|_2 \cdot \|\tilde{Q}^H R x - Q^H b\|_2 \stackrel{Q \text{ unitaria}}{\leq} \|\tilde{Q}^H R x - Q^H b\|_2 \Rightarrow$$

$$R = \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix}, Q^H = (\hat{Q} | \tilde{Q})^H = \left(\frac{\hat{Q}^H}{\tilde{Q}^H} \right)$$

$$\forall y \in \mathbb{K}^n \quad \|Ay - b\|_2^2 = \|\hat{R}y - \hat{Q}^H b\|_2^2 + \|\tilde{Q}^H b\|_2^2$$

$$(x) y = x \Rightarrow \hat{R}x = \hat{Q}^H b \Rightarrow \|Ay - b\|_2^2 = \|\tilde{Q}^H b\|_2^2 = \|Ax - b\|_2^2$$

$$\text{Así que } x = \min \{\|Ay - b\|_2^2 : y \in \mathbb{K}^n\} \Leftrightarrow x = \hat{R}^{-1}(\hat{Q}^H b)$$

Resumido:

También se puede obtener x : $A^{H^*} A x = A^{H^*} b$ pues

$$\|A^{H^*} A x - A^{H^*} b\|_2^2 = \langle A^{H^*} A x - A^{H^*} b, u \rangle = \langle Ax - b, Au \rangle = 0$$

$$\forall v \in \mathbb{R}^n \quad \langle Ax - b, Au \rangle, \text{ en particular } u = A^{H^*} A x - A^H b \rightarrow$$

$$\Leftrightarrow A^{H^*} A x - A^{H^*} b = 0 \Leftrightarrow A^{H^*} A x = A^{H^*} b.$$

III. Usando SVD:

$$A^{H^*} A x = A^{H^*} b \Leftrightarrow (U \Sigma V^{H^*})^H (U \Sigma V^{H^*}) x = (U \Sigma V^{H^*})^{H^*} b \Leftrightarrow$$

$$A = U \Sigma V^{H^*} \text{ con } U, V \text{ ortogonales} \quad (\Rightarrow U^{H^*} = U^{-1}, V^{H^*} = V^{-1})$$

$$\Leftrightarrow \hat{\Sigma}^{H^*} \Sigma V^{H^*} x = \hat{\Sigma}^{H^*} U^{H^*} b \Leftrightarrow \left[\begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix} \left(\begin{array}{c|c} \Sigma & 0 \\ \hline 0 & 0 \end{array} \right) = \hat{\Sigma}^2 \right] \Rightarrow$$

$$\Rightarrow \hat{\Sigma}^2 V^{H^*} x = (\hat{\Sigma}^2 I) U^{H^*} b \Leftrightarrow \circledast$$

$$U^{H^*} b = \begin{pmatrix} u_1^{H^*} \cdot b \\ \vdots \\ u_m^{H^*} \cdot b \end{pmatrix}$$

$$\hat{\Sigma}^{H^*} U^{H^*} = \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \end{pmatrix} \begin{pmatrix} u_1^{H^*} \\ \vdots \\ u_m^{H^*} \end{pmatrix} = \begin{pmatrix} \sigma_1 u_1^{H^*} \\ \vdots \\ \sigma_n u_n^{H^*} \end{pmatrix} \Rightarrow \hat{\Sigma}^{H^*} U^{H^*} b = \begin{pmatrix} \sigma_1 u_1^{H^*} \cdot b \\ \vdots \\ \sigma_n u_n^{H^*} \cdot b \end{pmatrix}$$

$$V^{H^*} x = \begin{pmatrix} v_1^{H^*} x \\ \vdots \\ v_n^{H^*} x \end{pmatrix}$$

$$\circledast \Leftrightarrow \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{pmatrix} V^{H^*} x = \begin{pmatrix} \sigma_1^2 v_1^{H^*} x \\ \vdots \\ \sigma_n^2 v_n^{H^*} x \end{pmatrix} = \begin{pmatrix} \sigma_1 u_1^{H^*} b \\ \vdots \\ \sigma_n u_n^{H^*} b \end{pmatrix} \Leftrightarrow \begin{pmatrix} v_1^{H^*} x \\ \vdots \\ v_n^{H^*} x \end{pmatrix} = \begin{pmatrix} \frac{1}{\sigma_1} u_1^{H^*} b \\ \vdots \\ \frac{1}{\sigma_n} u_n^{H^*} b \end{pmatrix}$$

$$\text{En conclusión, } A^{H^*} A x = A^{H^*} b \Leftrightarrow x = V \hat{\Sigma}^{-1} U^{H^*} b$$

TEMA 2

Sea E un espacio vectorial sobre un cuerpo \mathbb{K} . Una **norma** sobre E es una aplicación $\|\cdot\|: E \rightarrow [0, +\infty)$ tq $\|x\|=0 \Leftrightarrow x=0$, $\forall x, y \in E \quad \|x+y\| \leq \|x\| + \|y\|$ y $\forall x \in E, a \in \mathbb{K} \quad \|ax\|=|a|\|x\|$

Teo.: Todas las normas definidas en un espacio de dimensión finita son equivalentes, es decir, $\forall \|\cdot\|, \|\cdot\|_* \exists a, b > 0 : \forall x \in \mathbb{K}^n \quad a\|x\|_* \leq \|x\| \leq b\|x\|_*$

Una **norma matricial** en $\mathcal{M}_n(\mathbb{K})$ es una norma $\|\cdot\|$ definida en $\mathcal{M}_n(\mathbb{K})$ que además cumple que $\forall A, B \in \mathcal{M}_n(\mathbb{K}) \quad \|AB\| \leq \|A\| \cdot \|B\|$.

Dada una norma $\|\cdot\|$ en \mathbb{K}^n , se define la **norma matricial subordinada** como

$$\|A\| = \sup \left\{ \frac{\|Ax\|}{\|x\|} : x \in \mathbb{K}^n \setminus \{0\} \right\} = \sup \left\{ \frac{\|Ax\|}{\|x\|} : \|x\| \leq 1 \right\} = \sup \left\{ \frac{\|Ax\|}{\|x\|} : \|x\|=1 \right\}$$

$$\text{Prop: } \|A\|_\infty = \max_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{x} \left\{ \sum_{i=1}^n |a_{ij}| \right\} = \max_{i=1, \dots, n} \|a_{i\cdot}\|_1$$

$$\|A\|_1 = \max_{x} \left\{ \frac{\|Ax\|_1}{\|x\|_1} : \|x\|_1 = 1 \right\} = \max_{j=1, \dots, n} \left\{ \sum_{i=1}^n |a_{ij}| \right\} = \max_{j=1, \dots, n} \|a_{\cdot j}\|_1$$

$$\|A\|_2 = \max_{x} \left\{ \frac{\|Ax\|_2}{\|x\|_2} : \|x\|_2 = 1 \right\} = \sqrt{\rho(A^T A)} = \|A^T A\|_2 = \rho(A) \quad \text{si } A \text{ es normal}$$

El **radiopectral** de una matriz A se define como $\rho(A) = \max\{|\lambda| : \lambda \in \sigma(A)\}$.

Definamos la **norma de Frobenius** como | Tiene la característica de que

$$\|A_F\|^2 = \sum_{i,j=1}^n |a_{ij}|^2 \quad \left| \quad \|I\|_F = \left(\sum_{i=1}^n 1^2 \right)^{1/2} = \sqrt{n} \neq 1. \right.$$

$\|\cdot\|_F$ no es subordinada a ninguna norma vectorial en \mathbb{K}^n .

Prop: U unitaria $\Rightarrow \|UA\|_2 = \|A\|_2 = \|A\|_F$. Además, $\|A\|_2 = \rho(A)$ si A es normal.

Teo: $A \in \mathcal{M}_{n \times n}(\mathbb{K})$ y $\|\cdot\|$ norma matricial $\Rightarrow \rho(A) \leq \|A\|$. Recíprocamente,

$\forall A \in \mathcal{M}_n(\mathbb{K}), \epsilon > 0 \quad \exists \|\cdot\|$ norma matricial subordinada : $\|A\| \leq \rho(A) + \epsilon$.

Coro: $\rho(A) = \min \{ \|A\| : \|\cdot\| \text{ norma matricial} \} = \min \{ \|A\|_1, \|A\|_\infty \} = \min \{ \max_{j=1, \dots, n} \|a_{\cdot j}\|_1, \max_{i=1, \dots, n} \|a_{i\cdot}\|_1 \}$.

Dada una familia de matrices $\{A_i\}_{i \in \mathbb{N}} \subseteq \mathcal{M}_n(\mathbb{K})$

$$\lim_{i \rightarrow +\infty} A_i = A \Leftrightarrow \|A_i - A\| \xrightarrow{i \rightarrow +\infty} 0$$

Definimos $S_i = \sum_{j=1}^i A_j$ y veamos:

Sucesiones y Series de Matrices

Teo: $\lim_{k \rightarrow +\infty} A^k = 0 \Leftrightarrow \forall x \in \mathbb{K}^n \quad \lim_{k \rightarrow +\infty} A^k x = 0 \Leftrightarrow \rho(A) < 1 \Leftrightarrow \exists \|\cdot\|$ subordinada : $\|A\| < 1$.

Coro: Si $\sum_{k=0}^{+\infty} a_k z^k < +\infty$ para $|z| < R \Rightarrow$ podemos construir $\sum_{k=0}^{+\infty} a_k A^k$ para $\rho(A) < R$, es decir, $\exists S \in \mathbb{K}^{n \times n} : S = \sum_{k=0}^{+\infty} a_k A^k$.

Si $\rho(A) < 1 \Rightarrow \sum_{n=0}^{+\infty} A^n = (I - A)^{-1}$

Teo: las matrices invertibles son un conjunto abierto.

Condiciónamiento

Dada una norma matricial subordinada $\|\cdot\|$ y $A \in M_n(\mathbb{K})$ invertible, se define el **nº de condición** de la matriz A CRA $\|\cdot\|$ por $\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$.

Teo.: Sea A una matriz invertible, x y $x + \Delta x$ soluciones de $Ax = b$ y

$$A(x + \Delta x) = b + \Delta b. \quad b \neq 0 \Rightarrow \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}.$$

A mal condicionada $\Rightarrow \|A\| \cdot \|A^{-1}\| \gg 1 \Rightarrow \Delta x \sim 10^3 \text{ ó } 10^4$.

Prop: Si $A \in M_n(\mathbb{K})$:

i) $\text{cond}(A) = \text{cond}(A^{-1})$, $\text{cond}(\alpha A) = \text{cond}(A)$, $\text{cond}(I) = 1$

ii) $\text{cond}_2(A) = \frac{\sigma_1(A)}{\sigma_n(A)} = \frac{\max\{\lambda : \lambda \in \sigma(A)\}}{\min\{\lambda : \lambda \in \sigma(A)\}}$

iii) A normal $\Rightarrow \text{cond}_2(A) = \frac{\|\lambda \max(A)\|}{\|\lambda \min(A)\|} = \rho(A) \cdot \rho(A^{-1})$.

iv) U unitaria $\Rightarrow \text{cond}_2(\text{U}) = 1$

v) U unitaria $\Rightarrow \text{cond}_2(\text{UA}) = \text{cond}_2(A\text{U}) = \text{cond}_2(\text{A}\text{U})$

Hoja apartado EDO's

El algoritmo de factorización LU con el criterio de Golubile en matrices tridiagonales también se conoce como **algoritmo de Thomas**

$$A = \begin{pmatrix} b_1 & c_1 & & \\ a_2 & \ddots & \ddots & 0 \\ & \ddots & \ddots & c_{n-1} \\ 0 & a_{n-1} & b_{n-1} & c_{n-1} \\ & a_n & b_n & 0 \end{pmatrix}_{n \times n} = L \cdot U = \begin{pmatrix} 1 & & & \\ \tilde{a}_2 & 0 & & \\ 0 & \tilde{a}_3 & 0 & \\ & \ddots & \ddots & 0 \end{pmatrix} \begin{pmatrix} \tilde{b}_1 & c_1 & & \\ \tilde{b}_2 & \tilde{b}_2 & \ddots & c_{n-1} \\ 0 & \tilde{b}_3 & \ddots & 0 \\ & & \ddots & \tilde{b}_n \end{pmatrix}$$

Si consideramos $\{\delta_i\}$ dada por $\delta_1 = b_1$, $\delta_k = b_k \delta_{k-1} - a_k c_{k-1} \delta_{k-2}$ $k=2, \dots, n$
 $(\det(A_k) = \delta_k) \Rightarrow \tilde{a}_j = a_j \frac{\delta_{j-2}}{\delta_{j-1}}$ $j=2, \dots, n$; $\tilde{b}_j = \delta_j / \delta_{j-1}$ $j=1, \dots, n$

Prop.: I) $(LU)_{kp} = 0$ si $|k-p| > 0$ II) $(LU)_{kk} = b_k$

III) $(LU)_{kk-1} = a_k$ IV) $(LU)_{kk+1} = c_k$ V) $(d_k := \det(A_k))$

TEMA 4

Jacobi

$$\text{Dada } Ax = b \rightarrow \begin{cases} a_{11}x_1 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + \dots + a_{mn}x_n = b_m \end{cases} \rightsquigarrow \begin{cases} a_{11}x_1 = b_1 - \sum_{j=2}^n a_{1j}x_j \\ a_{21}x_1 = b_2 - \sum_{j=2}^n a_{2j}x_j \\ \vdots \\ a_{m1}x_1 = b_m - \sum_{j=2}^n a_{mj}x_j \end{cases}$$

$$\Rightarrow \forall j = 1, \dots, n \quad x_j = \frac{b_j - \sum_{i \neq j} a_{ij}x_i}{a_{jj}}$$

→ PROCESO ITERATIVO

$$\text{Dado } x^0 \in \mathbb{K}^n \text{ tomamos } \{x^k\} : x_i^{k+1} = \frac{b_i - \sum_{j \neq i} a_{ij}x_j^k}{a_{ii}}$$

$$A = D - E - F \text{ donde } -E \rightarrow (D) \quad D \rightarrow (0) \quad y \quad F \rightarrow (0) \Rightarrow$$

$$\Rightarrow x^{k+1} = D^{-1}(b + Ex^k + Fx^k) = \underbrace{D^{-1}b}_C + \underbrace{D^{-1}(E+F)x^k}_T \Rightarrow x^{k+1} = T_j x^k + C_j \quad k > 0$$

$$\text{Jacobi} \rightarrow T_j = D^{-1}(E+F), \quad C_j = D^{-1}b.$$

$$\text{En } \text{Gauss-Seidel} \text{ hacemos } x^{k+1} = D^{-1}b + D^{-1}Ex^{k+1} + D^{-1}Fx^k$$

$$\Rightarrow (I - D^{-1}E)x^{k+1} = D^{-1}Fx^k + D^{-1}b \Rightarrow (D - E)x^{k+1} = Fx^k + b$$

$$\Rightarrow x^{k+1} = T_{GS}x^k + C_{GS} \text{ donde } T_{GS} = (D - E)^{-1}F, \quad C_{GS} = (D - E)^{-1}b$$

$$\text{Sor} \quad x_{SOR}^{k+1} = \omega x_{GS}^{k+1} + (1-\omega)x_{GS}^k \Rightarrow (x_{SOR}^{k+1})_i = \omega \frac{b_i - \sum_{j \neq i} a_{ij}x_j^{k+1} - \sum_{j \neq i} a_{ij}x_j^k}{a_{ii}} + (1-\omega)(x_{GS}^k)$$

$$\Rightarrow x_{SOR}^{k+1} = \omega D^{-1}b + \omega D^{-1}Ex^{k+1} + \omega D^{-1}Fx^k + (1-\omega)(D^{-1}b + D^{-1}Ex^k + D^{-1}Fx^{k-1})$$

$$\Rightarrow x_{SOR}^{k+1} = \omega D^{-1}b + \omega D^{-1}Ex^{k+1} + \omega D^{-1}Fx^k + (1-\omega)x^k \Rightarrow$$

$$\Rightarrow Dx^{k+1} = wb + \omega Ex^{k+1} + \omega Fx^k + (1-\omega)x^k \Rightarrow (D - \omega E)x^{k+1} = ((1-\omega)D + \omega F)x^k + wb$$

$$\text{En resumen, } x^{k+1} = T_{SOR}x^k + C_{SOR(w)} \text{ donde } T_{SOR(w)} = (D - \omega E)^{-1}((1-\omega)D + \omega F),$$

$$C_{SOR(w)} = wb.$$

En general, podemos tener el proceso iterativo:

$$\rightarrow \text{Dado } x^0, \text{ obtenemos } x^k \text{ tq } x^{k+1} = Tx^k + C \text{ con } k \geq 0.$$

Es fácil ver que $Ax = b \Leftrightarrow x = Tx + C$ en los 3 casos.

Tutor y
Centro

$$x = Tx + C, \quad x^{k+1} = Tx^k + C$$

$$x^{k+1} - x := e^{k+1} = T(x^k - x) = T^2(x^{k-1} - x) = \dots = T^{k+1}(x^0 - x)$$

$$\|e^k\| \rightarrow 0 \Leftrightarrow \|T^k\| \rightarrow 0 \Leftrightarrow f(T) \leq 1.$$

→ Idea general: Sea $Ax = b$ con $A = M - N$ donde M sea fácilmente invertible.

→ $Mz = d$ se resuelve fácilmente.

$$Ax = b \Leftrightarrow (M - N)x = b \Leftrightarrow Mx = Nx + b \Leftrightarrow x = (M^{-1}N)x + M^{-1}b$$

Denominando $T = M^{-1}N$, $C = M^{-1}b \Rightarrow Mc = b$, entonces, $Ax = b \Leftrightarrow x = Tx + C$

→ ALGORITMO: Dado x^0 , obtenemos x^{k+1} con $k \geq 1$ como $x^{k+1} = Tx^k + C$ para $k \geq 0$.

$$\text{Jacobi: } T_j = D^{-1}(E+F), \quad C_j = D^{-1}b$$

$$\text{¿ } A = M - N : T = M^{-1}N ? \quad \text{¿ } C = M^{-1}b ? \Rightarrow M = b, \quad N = E + F$$

Condición de parada

Paramos si $\|e^k\| < \varepsilon$ donde $e^k = x^k - x$, el problema es que si no se conoce $x \Rightarrow$ no podemos calcular e^k . Para solucionar este problema consideramos el **residuo** definido como $r^k = b - Ax^k$

$\|r^k\| \ll 1 \not\Rightarrow \|x^k - x\| \ll 1$, pero sí se cumple que

$$x - x^k = A^{-1}(Ax - Ax^k) = A^{-1}(b - Ax^k) = A^{-1} \cdot r^k \Rightarrow e^k = A^{-1} r^k$$

$$A(x - x^k) = Ax - Ax^k = b - Ax^k = r^k$$

Luego, $\|e^k\| \leq \|A^{-1}\| \cdot \|r^k\|$. En conclusión, un criterio de parada razonable es:

$$\frac{\|r^k\|}{\|r^0\|} < \varepsilon$$

Matrices especiales

Una matriz $A = (a_{ij})$ es **estrictamente diagonal dominante** si $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$.

A estrictamente diagonal dominante $\Rightarrow A$ es no singular.

Prop.: A estrictamente dominante \Rightarrow Jacobi y Gauss-Seidel convergen. Es más, diagonal $\|T_G\|_\infty \leq \|T_J\|_\infty < 1$

Prop.: A es SPD $\Leftrightarrow \forall k=1, \dots, n \quad A_k$ es SPD donde $A_k = (a_{(1:k, 1:k)})$.

Si $\lambda \in \sigma(A)$, $\lambda > 0$, y A es simétrica $\Rightarrow A$ es SPD.

Sea $\{v_1, \dots, v_n\}$ base ortogonal de autovalores

$$\forall x \quad \exists \lambda_i \text{ (no todos nulos)} : x = \sum_{i=1}^n \lambda_i v_i \Rightarrow x^t A x = \sum_{i=1}^n \lambda_i^2 \|v_i\|^2.$$

$\lambda_i v_i = \lambda_i v_i \text{ con } \lambda_i > 0$

T^a de Gershgorin: Sea $A = (a_{11} \cdots a_n)$ y consideramos $\delta_i = \sum_{j \neq i} |a_{ij}| \Rightarrow$

$$\Rightarrow \sigma(A) \subset \bigcup_{i=1}^n D_i \text{ donde } D_i = \{z \in \mathbb{C} : |a_{ii} - z| < \delta_i\}$$